

BCM0505-15 - Processamento da Informação

May 19, 2020

Laboratório L05 – 19/05

Instruções

- Membros das turmas NA1 e NB(4,5) deverão submeter códigos em Python para todos os exercícios nesta página em um único arquivo [.py](#) via [Tidia](#) até 26/05 às 19h – sob a entrada **E9**.

Exercícios

- (01) Vetorização de Matrizes.**

Seja $A : [0 \dots m - 1] \times [0 \dots n - 1] \rightarrow \mathbb{R}$ uma matriz de reais com m linhas e n colunas. A *vetorização* de A , denotada por $\mathcal{V}ec(A)$ é a imersão de A em uma lista de dimensão mn , em que as linhas de A ocorrem uma após a outra. Exemplo:

$$A = \begin{pmatrix} 2 & 1 & 0 & 4 \\ 3 & 0 & 2 & -1 \\ 0 & 1 & 0 & 1 \end{pmatrix} \quad \text{e} \quad \mathcal{V}ec(A) = [2, 1, 0, 4, 3, 0, 2, -1, 0, 1, 0, 1].$$

Escreva uma função que recebe A e devolve $\mathcal{V}ec(A)$.

Solução:

Uma versão *feijão-com-arroz*.

```
def vectorize (A: [[float]]) -> [float]:
    m, n, k = len(A), len(A[0]), 0
    vecA = [0] * (m*n)
    for i in range (m):
        for j in range (n):
            vecA[k] = A[i][j]
            k += 1
    return vecA
```

Uma versão com [append](#).

```
def vectorize (A: [[float]]) -> [float]:
    vecA = []
    for i in range (len (A)):
        for j in range (len (A[0])):
            vecA.append (A[i][j])
    return vecA
```

Uma versão mais sucinta utilizando *list comprehensions*.

```
def vectorize (A: [[float]]) -> [float]:
    return [A[i][j] for j in range (len (A[0])) for i in range (len (A))]
```

Uma versão utilizando [itertools](#).

```
import itertools as itt
def vectorize (A: [[float]]) -> [float]:
    return list (itt.chain.from_iterable (A))
```

☐

- (02) Matriz Diagonal Dominante.**

Uma matriz $A : [0 \dots n - 1] \times [0 \dots n - 1] \rightarrow \mathbb{R}$ é *diagonal dominante* se os elementos de cada linha são menores ou iguais ao elemento da mesma linha que reside na diagonal principal. Em forma simbólica, A é diagonal dominante se

$$A[i][i] \geq A[i][j] \quad \text{para todo} \quad 0 \leq i, j \leq n - 1.$$

Escreva uma função que recebe uma matriz A e determina se A é diagonal dominante.

Solução:

```
def is_diagonal_dominant (A: [[float]]) -> bool:
    n = len(A)
    for i in range (n):
        for j in range (n):
            if A[i][i] < A[i][j]:
                return False
    return True
```

☐

- (03) Matrizes Seguras.**

Seja $A : [0 \dots n - 1] \times [0 \dots n - 1] \rightarrow \{0, 1\}$ uma matriz quadrada de números binários. Dizemos que A é *segura* se dois ou mais 1's não ocorrem: (i) na mesma linha; (ii) na mesma coluna; (iii) na mesma diagonal (nos sentidos principal e secundário). Por exemplo,

$$\begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix} \quad \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \quad \begin{pmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \end{pmatrix}$$

a matriz da esquerda é segura, a do meio e a da direita não. Escreva uma função que recebe A e decide se ela é segura.

Solução:

```
def is_safe (A: [[int]]) -> bool:
    n = len(A)

    # verificação das linhas e colunas
    for i in range (n):
        onesrow = onescol = 0
        for j in range (n):
            if A[i][j] == 1: onesrow += 1
            if A[j][i] == 1: onescol += 1
        if onesrow > 1 or onescol > 1:
            return False

    # verificação das diagonais principais e secundárias
    for d in range (-n+1,n):
        onesfst = onessnd = 0
        for k in range (n-abs(d)):
            if A[k-min(0,d)][k+max(0,d)] == 1: onesfst += 1
            if A[k-min(0,d)][n-1-(k+max(0,d))] == 1: onessnd += 1
        if onesfst > 1 or onesnd > 1:
            return False

    return True
```

☐

- (04) Produto de Krönecker.**

Para duas matrizes $A \in \mathbb{R}^{k \times \ell}$ e $B \in \mathbb{R}^{m \times n}$, o *produto de Krönecker* ou *tensorial* entre A e B , denotado por $A \otimes B$, é uma matriz de blocos que possui dimensões $km \times \ell n$ e é dada por:

$$A \otimes B = \begin{pmatrix} a_{0,0}B & \cdots & a_{0,\ell-1}B \\ \vdots & \ddots & \vdots \\ a_{k-1,0}B & \cdots & a_{k-1,\ell-1}B \end{pmatrix}, \quad \text{em que} \quad a_{i,j}B = \begin{pmatrix} a_{i,j}b_{0,0} & \cdots & a_{i,j}b_{0,n-1} \\ \vdots & \ddots & \vdots \\ a_{i,j}b_{m-1,0} & \cdots & a_{i,j}b_{m-1,n-1} \end{pmatrix}.$$

Por exemplo, se

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \quad \text{e} \quad B = \begin{pmatrix} 0 & 5 \\ 6 & 7 \end{pmatrix}, \quad A \otimes B = \begin{pmatrix} 1 \begin{pmatrix} 0 & 5 \\ 6 & 7 \end{pmatrix} & 2 \begin{pmatrix} 0 & 5 \\ 6 & 7 \end{pmatrix} \\ 3 \begin{pmatrix} 0 & 5 \\ 6 & 7 \end{pmatrix} & 4 \begin{pmatrix} 0 & 5 \\ 6 & 7 \end{pmatrix} \end{pmatrix} = \begin{pmatrix} 0 & 5 & 0 & 10 \\ 6 & 7 & 12 & 14 \\ 0 & 15 & 0 & 20 \\ 18 & 21 & 24 & 28 \end{pmatrix}.$$

Escreva uma função que recebe A e B e devolve $A \otimes B$.

Solução:

```
def tensor_product (A: [[float]], B: [[float]]) -> [[float]]:
    mA, nA = len (A), len(A[0])
    mB, nB = len (B), len(B[0])
    C = [[0 for j in range (nA*nB)] for i in range (mA*mB)]

    for i in range (mA):
        for k in range (mB):
            for j in range (nA):
                for l in range (nB):
                    C[i*mB+k][j*nB+l] = A[i][j]*B[k][l]
    return C
```

☐

- (05) Autovetor Dominante.**

Seja $A : [0 \dots n - 1] \times [0 \dots n - 1] \rightarrow \mathbb{R}$ uma matriz quadrada de valores reais. Um vetor $x[0 \dots n - 1]$ de reais não nulos é um *auto-vetor* de A se $Ax = \lambda x$, para algum $\lambda \in \mathbb{R}$ chamado *auto-valor* de A associado a x . Um auto-vetor é *dominante* se o valor absoluto de seu auto-valor é um máximo dentre os demais auto-valores (em absoluto) de A .

O método iterativo a seguir calcula uma aproximação para o auto-vetor dominante de A : seja $x_0[0 \dots n - 1]$ um vetor inicial não nulo e $m > 0$ um inteiro; faça

$$x_{k+1} = \frac{Ax_k}{\|Ax_k\|} \quad \text{enquanto} \quad k \leq m.$$

Note que: Ax_k é o produto da matriz A com o vetor x_k que resulta em um vetor y , e que $\|Ax_k\| = \|y\|$ é a norma euclidiana (comprimento) do vetor y , que pode ser calculada como a raiz quadrada do produto interno $\langle Ax_k, Ax_k \rangle$; isto é, $\|y\| = \sqrt{\sum_{i=0}^{n-1} y_i^2}$.

(a) Escreva uma função que recebe A e m e devolve uma aproximação para o auto-vetor dominante de A .

Solução:

```
from math import sqrt

def euclid_norm (z: [float]) -> float:
    return sqrt (zi*zi for zi in z)

def matrix_prod_vector (A: [[float]], x: [float]) -> [float]:
    return [sum (aij*xj for aij, xj in zip (ai, x)) for ai in A]

def power_method (A: [[float]], x: [float], m: int):
    for k in range (1,m+1):
        x = matrix_prod_vector (A, x)
        c = euclid_norm (x)
        if c == 0: return (False, x)
        for j in range (len(x)):
            x[j] /= c
    return (True, x)
```

☐

(b) É sempre possível devolver um auto-vetor dominante? Por que? O que ocorre caso não seja possível devolvê-lo?


Solução:

Subjacente está o fato de que estamos trabalhando em \mathbb{R} : as matrizes, os vetores e os escalares são todos reais. Existem, no entanto, matrizes reais (i.é, todas as entradas são valores reais) nas quais:

- todos os auto-valores são complexos (ex., matrizes anti-simétricas),
- todos os auto-vetores são todos complexos (ex., matrizes de rotação).

Para esses casos, precisaríamos revisar o código acima para lidar com valores complexos.

☐



Aritanan Gruber

Assistant Professor

"See, if y'all haven't the same feeling for *this*, I really don't give a damn. If you ain't feeling it, then dammit *this* ain't for you!"

(desconheço a autoria; agradeço a indicação)